

Raport Tehnic – Analiza Automată a semnalelor EMS

Nicoale Gabriel, Alecu Emanuel-Ioan

Scopul acestui proiect este de a dezvolta un sistem tip software pentru procesarea și clasificarea semnalelor electromiografice de suprafață (sEMG), utilizând tehnici de învățare automată (Machine Learning).

Obiectivele principale constau în distincția precisă între trei tipuri de exerciții de flexie, înregistrate la nivelul antebrațului, și evaluarea dezechilibrului muscular funcțional între grupele musculare agoniste (flexori) și antagoniste (extensori).

Pentru realizarea lucrării, a fost utilizată baza de date “EMG Database 1”, ce conține înregistrări de la diferiți subiecți, realizate cu un dispozitiv cu 8 canale și o frecvență de eșantionare de 1000 Hz. Protocolul include trei clase de mișcare și perioade de repaus.

Deoarece semnalul EMG brut este nestaționar, s-au aplicat următorii pași de procesare:

- Eliminarea componentei continue, ce reprezintă scăderea valorii de baza (128) pentru centrarea semnalului în zero.
- Segmentarea temporală (Windowing), ce constă în împărțirea semnalului în ferestre de analiză de 200 ms cu o suprapunere de 50 ms. Aceasta permite extragerea trăsăturilor în timp real și mărește numărul de exemple pentru antrenare.

Pentru fiecare fereastră și fiecare canal, s-a calculat un vector compus din metrici în domeniul timpului, selectate pentru eficiență. Vectorul final de intrare pentru clasificator are dimensiunea de 8 canale, fiecare deținând 6 trăsături, în total fiind 48 de atribute.

Clasificarea celor trei tipuri de mișcare a fost realizată utilizând algoritmul Random Forest Classifier, unde setul de date a fost împărțit în 70% date de antrenare și 30% date de testare, folosind stratificare pentru a menține proporția claselor.

Pentru a putea evalua asimetria, s-a implementat o metodă de detecție dinamică a canalelor, structurată în 4 pași:

1. Identificarea automată a canalului cu puterea maximă a semnalului (RMS – Root Mean Square) ca fiind flexorul principal.

2. Selectarea canalului diametral opus (la 4 poziții distanță pe dispozitiv) ca fiind extensorul
3. Calculul coeficientului de asimetrie folosind formula $K_{As} = \frac{|X_1 - X_2|}{\max(X_1, X_2)} \cdot 100\%$, unde X_1 reprezintă valoarea RMS a grupei musculare care cea mai mare energie acel moment, iar X_2 descrie valoarea RMS a grupei musculare opuse.
4. Incadrarea subiecților în clase de risc

În urma analizelor, folosind modelul Random Forest, s-a obținut o acuratețe globală de 94,79%, urmată de parametrul F1-Score de 0,95 pentru toate cele trei clase. Matricea de confuzie indică o rată scăzută de eroare, confuziile fiind neglijabile între clasele adiacente. Acestea validează robustețea trăsăturilor alese, în special a lungimii semnalului (WL – Waveform Length) și a valorii RMS, pentru discriminarea modelelor de mișcare.

Studiul a relevat o asimetrie la nivel ridicat (Clasa 4, cu procent mai mare decât 40%) în majoritatea cazurilor de flexie activă. De exemplu, pentru subiectul 0, prima mișcare înregistrează o valoare K_{As} de 94,88%, reprezentând un rezultat încadrat în clasa de asimetrie ridicată. În timpul unei flexii, mușchii flexori sunt mult mai puternic activați, în timp ce extensorii sunt relaxați. Diferența mare de energie între cele două grupe indică o execuție corectă a exercițiului. Posibilitatea unei suspiciuni ar fi fost prezentă în cazul în care asimetria era la nivel ridicat în stare de repaus.

În concluzie, proiectul a demonstrat că utilizarea unui set redus de trăsături în domeniul timpului, combinat cu un clasificator neliniar, permite recunoașterea mișcărilor mâinii cu o precizie de aproape 95%. Implementarea algoritmului de detecție dinamică a canalelor a eliminat erorile potențiale cauzate de poziționarea variabilă a senzorilor, oferind o metodă robustă de evaluare a echilibrului muscular în timpul efortului.

Codul sursă poate fi accesat pe GitHub, accesând următorul link: <https://github.com/gabrielnicolae1006/Proiect-EMG.git>